

Inteligência Computacional

Classificação de Pokémon com Descritores de Imagens

Introdução

Este trabalho desenvolve um sistema inteligente para classificar automaticamente imagens dos Pokémon Bulbasaur, Charmander e Squirtle.

A solução combina extração de características com LBP e VGG16, e avalia o desempenho de três classificadores:

- k-NN
- SVM
- Árvore de Decisão

Base de dados

A base de dados foi obtida da plataforma Kaggle, contendo ao todo 337 imagens divididas em três classes (Bulbasaur, Charmander e Squirtle). Foram usadas 216 imagens para treino e 121 para teste.

Extração de Características

Foi utilizada uma abordagem de combinação de características, unindo textura (LBP) e características profundas (VGG16):

- LBP: aplicado em imagens em escala de cinza. P=8, R=2 e método nri_uniform.
- VGG16: rede pré-treinada usada para extrair deep features de imagens RGB (224×224).
- Vetor final: concatenação LBP + VGG16 = 109 dimensões.

Pré-processamento

O vetor de características combinado foi submetido a um pipeline de pré-processamento com os seguintes passos:

- Normalização: os dados foram padronizados com StandardScaler para garantir escala compatível entre as características.
- Balanceamento: aplicou-se a técnica SMOTE (Synthetic Minority Over-sampling Technique) para corrigir o desequilíbrio entre as classes, gerando amostras sintéticas das minoritárias.

k-Nearest Neighbors (k-NN)

Melhores hiperparâmetros encontrados:

- Número de vizinhos (k): 7
- Peso dos vizinhos: distance (vizinhos mais próximos têm maior influência)
- Métrica de distância: cosine
- PCA adicional aplicado para preservar 85% da variância

Support Vector Machine (SVM)

Melhores hiperparâmetros (via RandomizedSearchCV):

- Kernel: linear
- C (Regularização): ≈ 0.0072
- Gamma (γ): ≈ 0.0022
- Peso de classes: None (classes tratadas igualmente)


Árvore de Decisão

Hiperparâmetros das árvores individuais:

- Critério de divisão: entropy
- Profundidade máxima: 10
- Mínimo de amostras para divisão: 10
- Mínimo de amostras por folha: 2
- Máximo de features por divisão: sqrt


Resultados

- A Árvore de Decisão apresentou o melhor desempenho, com acurácia de **86,78%** e F1-Score médio de **0,87**.



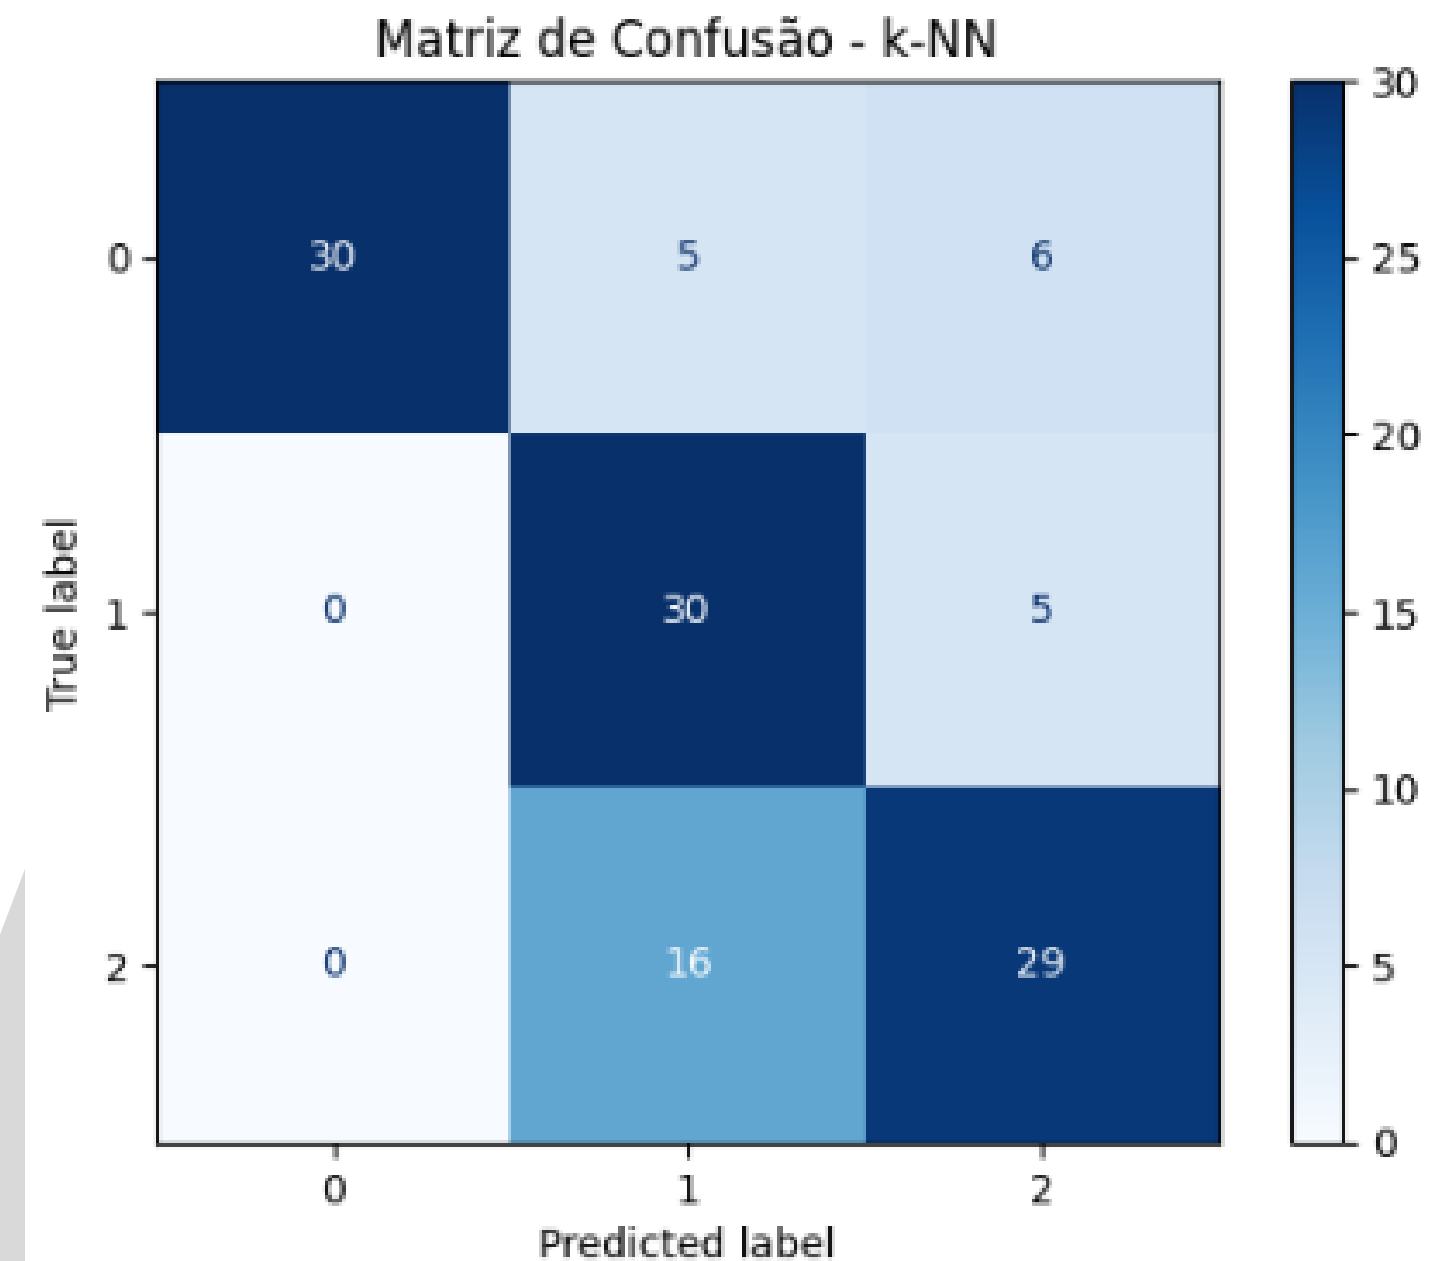
Resultados

- O Support Vector Machine (SVM) obteve uma acurácia de **80,99%** e F1-Score médio de **0,81**.



Resultados

- Já o k-NN alcançou acurácia de **73,55%** e F1-Score médio de **0,74**.



Considerações finais

- O sistema obteve ótimos resultados, com destaque para a Árvore de Decisão.
- A extração com VGG16 é custosa, pode reduzir o desempenho.
- A combinação de LBP + VGG16 se mostrou eficaz, e a otimização de hiperparâmetros foi essencial.
- Modelos com fronteiras complexas, como árvores, superaram o k-NN, que teve pior desempenho.